



컴퓨팅의 새로운 시대: 에이전틱 AI를 위한 통합 시스템 아키텍처

NVIDIA가 설계한 생성형 AI에서 에이전트 기반 인프라로의 진화



GTC 전략 요약 보고서

토큰 경제의 도래: 컴퓨팅은 곧 수익입니다



AI가 유용한 코드를 생성하고 자율적으로 작업을 수행함에 따라, '토큰'은 가장 수익성 높은 비즈니스 단위가 되었습니다. 인프라의 전력당 처리량(Throughput per watt)이 곧 비즈니스의 수익률을 결정합니다.


패러다임의 전환: 수동적 '생성'에서 자율적 '실행'으로

	생성형 AI (과거)	에이전틱 AI (현재와 미래)
컴퓨팅 패턴	클릭 및 타이핑 입력	의도 전달 및 도구의 자율적 사용
산출물	질문에 대한 단순 답변	실제적인 작업 수행 및 행동
메모리 구조	무상태성 (Stateless)	KV 캐시 및 장/단기 기억의 완벽한 통합
인프라 요구사항	표준 클라우드 컴퓨팅	목적 지향적 AI 팩토리

에이전틱 루프: 분산형 자율 컴퓨팅의 핵심 구조

에이전트는 단일 소프트웨어가 아닙니다.

모델(뇌), 하네스(몸통), 도구(손), 그리고 런타임(작업실)이 결합된 고도의 분산 컴퓨팅 아키텍처입니다.




통합 에이전틱 청사진: 데이터센터에서 물리적 물리적 세계까지

	데이터센터	엔터프라이즈	개인용 PC	물리적 세계
하드웨어 엔진	Vera Rubin & DSX	DGX Systems	RTX Spark	Jetson Thor
운영 체제 / 하네스	DSX OS	OpenShell	Windows AI	Halos & Isaac
기반 오픈 모델	NemoTron	맞춤형 기업 모델	로컬 소형 모델	Cosmos 3 & Alpha Mayu

단일한 에이전틱 컴퓨팅 패턴이 모든 산업의 스케일에 맞춰
완벽하게 최적화되어 구동됩니다.

AI 팩토리의 해부학: DSX 아키텍처



DSX Max LPS (45°C 온수 냉각)

전력 예산 내에서 더 많은 GPU를 안전하게 배포하여 과잉 프로비저닝을 최대 40% 제거합니다.

동적 전력 할당 (Dynamic Power Allocation)

랙 간 잉여 전력을 회수하여 작업이 집중되는 곳으로 실시간 재분배합니다.


DSX Flex (전력망 통합)

실시간 전력망 신호를 읽고 공장 전력을 동적으로 조정하여 100 GW 규모의 부하를 완화합니다.

**AI 팩토리는 단순한 데이터센터가 아닙니다.
칩, 네트워크, 전력, 냉각이 '초미세 공동 설계'로 통합된 단일 엔진입니다.**

물리적 제약을 극복하는 디지털 트윈 (DSX-SIM)

디지털 공간 (Omniverse Blueprint)



물리적 현실




기가와트(GW) 당 최대 1,000억 달러가 투입되는 인프라는 첫 번째 시도에서 완벽하게 작동해야 합니다. NVIDIA 파트너들은 물리적인 랙을 설치하기 전에 디지털 트윈에서 전력, 냉각, 네트워크의 모든 변화를 완벽히 시뮬레이션하고 검증합니다.

Vera Rubin: 에이전틱 AI를 위해 설계된 멀티 랙 슈퍼컴퓨터

NVLink 72 & Bluefield 4

에이전트의 컨텍스트 기억 및 실시간
보안 스토리지를 가속합니다.



무케이블 아키텍처

복원력을 극대화하고 조립 시간을
2시간에서 단 5분으로 단축시킵니다.

극단적 공동 설계

6조 개의 트랜지스터, 3nm 공정,
HBM4 메모리를 단일 시스템으로
완벽히 통합했습니다.


Vera Rubin은 추론(Inference)을 넘어 에이전트의 관찰, 추론, 계획, 메모리 관리를
동시에 처리하는 본격적인 '에이전틱 전용 시스템'입니다.

인간을 위한 CPU에서 에이전트를 위한 CPU로

	기존 x86 아키텍처	NVIDIA Vera 아키텍처
설계 대상	인간 (Humans)	AI 에이전트 (AI Agents)
핵심 지표	임대형 병렬 처리량 (Throughput)	초저지연 및 고도의 상호작용 (Ultra-low Latency)
아키텍처 초점	분할된 칩렛 (Chiplets)	단일 모놀리식 메시 & 막대한 대역폭 (LPDDR5X 1.2TB/s)
실제 성능	표준 기준점	샌드박스 실행 1.8배, SQL 처리 3배, 실시간 스트림 6배 속도 향상

10개의 명령어를 동시에 디코딩하는 Olympus 코어는 대기 시간이 없는 즉각적인 에이전트 도구 호출을 가능하게 합니다.

엔터프라이즈 AI 툴킷: 기업용 자율 에이전트 구축 스택



모델 (NemoTron 3 Ultra)

5배 빠르고 30% 저렴한 하이브리드(SSM+MoE) 아키텍처 개방형 기반 모델.

하네스 (NVIDIA OpenShell)

기업의 보안 정책, 데이터 프라이버시, 에이전트 권한을 통제하는 오케스트레이션 셀.


도구 (CUDAX Libraries)

에이전트가 직접 학습하고 활용할 수 있는 수천 개의 수학 및 과학 연산 라이브러리.

런타임 (NVIDIA AI Platform)

온프레미스, 클라우드, 엣지 기기를 아우르는 최적화된 실행 환경.

산업 혁신의 실사례: Cadence 칩 설계 슈퍼 에이전트




40배 속도 향상

수십 개의 전문 서브 에이전트가 스스로 버그를 식별하고 코드를 수정하여, 수주(Weeks)가 걸리던 칩 검증 주기를 단 수시간(Hours)으로 단축했습니다.

개인용 컴퓨팅의 재발명: NVIDIA RTX Spark

Blackwell RTX GPU

6,144개의 CUDA 코어, 1 Petaflop의 막강한 AI 연산 성능.




MediaTek 20-Core Grace CPU

3nm 공정과 128GB 통합 메모리로 설계된 전력 효율성.

100% CUDA 및 Windows 호환

40년 전 Windows 95가 PC를 대중화했다면, RTX Spark는 PC를 '개인용 무제한 AI 에이전트'로 재탄생시킵니다.
클라우드 연결 없이 로컬에서 중단 없이 작업을 수행하는 완벽히 안전한 샌드박스입니다.


데이터 패러다임의 역전: 세계 모델 Cosmos 3



물리적 AI의 가장 큰 장벽은 '1인칭 데이터'의 부재였습니다.
Cosmos 3는 텍스트나 이미지로부터 물리 법칙에 완벽히 부합하는 합성 비디오를 생성해내는 세계 모델(World Model)입니다.
이제 컴퓨팅 엔진이 스스로 무한한 교사(Teacher) 데이터를 생성합니다.


세상의 모든 움직임을 위한 AI: 자율주행과 휴머노이드

Alpha Mayu 2 (AV 모델)



시각 정보에 반응하는 것을 넘어, 상황의 맥락을 끊임없이
'스스로 추론(Reasoning)'하며 주행하는 자율 오픈 모델.

Isaac Groot (로봇 레퍼런스)



150파운드, 6피트, 각 손에 25개의 자유도(DoF)를 갖춘
휴머노이드. Jetson Thor 탑재로 완벽한 통합 플랫폼 제공.

완벽히 준비된 미래: 지금, 혁신을 배포하십시오

